پروژه درس آمار - پاییز ۱۴۰۵

From Statistical Foundations to Reproducible Research

تهیه‌شده توسط تیم دستیاری درس

این سند چارچوب رسمی پروژه‌ی درس آمار را توضیح می‌دهد. پروژه در پنج فاز انجام می‌شود و هدف آن این است که مفاهیم اصلی درس را روی مجموعه‌داده‌های واقعی، به‌صورت مرحله‌به‌مرحله و قابل بازتولید به کار ببرید. تمرکز پروژه بر شناخت درست داده، آمار توصیفی، احتمال، نمونه‌گیری و استنباط، و در ادامه رگرسیون و همبستگی است.
هدف پروژه رسیدن به یک نتیجه‌ی ازپیش تعیین‌شده یا تولید یک کار مقاله‌محور نیست. ارزیابی بر صحت آماری، شفافیت تحلیل، کیفیت تفسیر، رعایت فرض‌ها، بازتولیدپذیری و توانایی دفاع از تصمیم‌های آماری انجام می‌شود.

۱. هدف، بازه‌ی زمانی و ماهیت پروژه

پروژه کاملاً **انفرادی** است. انتخاب سؤال، آماده‌سازی داده، کدنویسی، تحلیل، تفسیر، تهیه‌ی شکل و جدول، نوشتن گزارش و دفاع شفاهی باید توسط خود دانشجو انجام شود.

شروع رسمی پروژه	۱۸ مهر ۱۴۰۵
پایان رسمی پروژه	۵ بهمن ۱۴۰۵
تعداد فازها	۵ فاز
نحوه‌ی انجام	انفرادی
مرجع اصلی تحویل‌ها	GitHub؛ نسخه‌ی آرشیوی تحویل در سامانه‌ی CW نیز بارگذاری می‌شود

مبنای نظری پروژه و ارتباط فازها با کتاب درس

مرجع اصلی طراحی فازهای پروژه کتاب زیر است:

[1] Thomas H. Wonnacott and Ronald J. Wonnacott, Introductory Statistics, 5th Edition, Wiley.

ترتیب فازها عمداً با منطق کتاب هماهنگ شده است:

- **فاز اول:** ماهیت آمار، نمونه‌گیری و مطالعه‌ی مشاهده‌ای در برابر آزمایش تصادفی، آمار توصیفی، جدول فراوانی، نمودار، مرکز و پراکندگی توزیع و استفاده‌ی درست از نمایش‌های گرافیکی.

- **فاز دوم:** احتمال، احتمال شرطی، استقلال، قضیه‌ی بیز در مسائل مناسب، متغیرهای تصادفی، توزیع‌های گسسته و پیوسته، توزیع دوجمله‌ای و نرمال، امید ریاضی، واریانس و دو متغیر تصادفی.
- **فاز سوم:** نمونه‌گیری و توزیع نمونه‌گیری، برآورد نقطه‌ای، فاصله‌ی اطمینان، bootstrap، آزمون فرض، مقایسه‌ی میانگین‌ها و نسبت‌ها و در صورت تناسب، تحلیل واریانس.
- **فاز چهارم:** برازش خط، کمترین مربعات معمولی، رگرسیون ساده و چندگانه، متغیرهای صفر و یک، تبدیل متغیرها، تشخیص مدل با نمودار باقیمانده، همبستگی و چندهم‌خطی.
- **فاز پنجم:** یکپارچه‌سازی مراحل قبل، بررسی استحکام نتیجه، مقایسه با تحلیل‌های جایگزین، محدودیت‌ها و گزارش نهایی منسجم.

۲. انتخاب مجموعه‌داده و مسیر پروژه

هر دانشجو فقط یکی از سه مسیر زیر را انتخاب می‌کند و هر پنج فاز را روی همان مسیر ادامه می‌دهد. تغییر مسیر پس از ثبت موضوع تنها با تأیید تیم دستیاری امکان‌پذیر است.

مسیر الف: NHANES 2021--2023

مسیر پایه ـ حداکثر ۱۰۰ امتیاز

NHANES یا National Health and Nutrition Examination Survey یک پیمایش بزرگ سلامت جمعیت است که توسط CDC/NCHS اجرا می‌شود. داده‌ها شامل اطلاعات جمعیت‌شناختی، پرسش‌نامه‌های سلامت و سبک زندگی، معاینات فیزیکی، اندازه‌گیری‌های بدنی، فشارخون و انواع داده‌های آزمایشگاهی هستند. دوره‌ی اوت ۲۰۲۱ تا اوت ۲۰۲۳ نخستین انتشار ملی NHANES پس از وقفه‌ی ناشی از همه‌گیری کرونا است و با طراحی نمونه‌گیری به‌روزشده و دستورالعمل‌های تحلیلی ویژه منتشر شده است.

ویژگی مهم این مسیر آن است که با یک **نمونه‌ی احتمالی پیچیده** روبه‌رو هستید. بنابراین تفاوت میان «افراد موجود در فایل» و «جمعیت مورد نمایندگی» اهمیت زیادی دارد و وزن‌های نمونه‌گیری، عدم پاسخ و طرح نمونه‌گیری باید در تفسیر نتایج مورد توجه قرار گیرند.

برای پروژه لازم نیست از همه‌ی فایل‌های **NHANES** استفاده کنید. هر دانشجو باید یک زیرمجموعه‌ی معنادار از متغیرها و یک جمعیت تحلیلی مشخص تعریف کند؛ برای مثال بزرگسالان بالای ۲۰ سال و متغیرهایی از حوزه‌ی فشارخون، شاخص‌های بدنی، خواب، فعالیت بدنی، مصرف دخانیات یا شاخص‌های آزمایشگاهی.

دسترسی رسمی:

- صفحه‌ی اصلی داده و مستندات دوره: CDC - NHANES 2021--2023
- صفحه‌ی فایل‌های عمومی: CDC - Public Data Files
- راهنمای طراحی نمونه و تحلیل: CDC - Sample Design and Analytic Guidance

مسیر ب: TCGA-BRCA

مسیر چندوجهی پیشرفته ـ حداکثر ۱۱۰ امتیاز؛ شامل ۱۰ امتیاز اضافه

TCGA-BRCA یا The Cancer Genome Atlas - Breast Invasive Carcinoma یک مجموعه‌داده‌ی چندوجهی درباره‌ی سرطان پستان است که در NCI Genomic Data Commons نگهداری می‌شود. برای یک بیمار ممکن است چند نوع داده‌ی متفاوت در دسترس باشد؛ از جمله اطلاعات بالینی و جمعیت‌شناختی، بیان ژن مبتنی بر RNA-seq، متیلاسیون DNA و دیگر داده‌های مولکولی عمومی. همین ساختار، این مسیر را برای تمرین ادغام چند منبع داده و مقایسه‌ی تحلیل تک‌وجهی و چندوجهی مناسب می‌کند.

در این مسیر استفاده‌ی واقعی از **حداقل دو نوع داده‌ی متفاوت** الزامی است. ترکیب‌های مناسب می‌توانند شامل موارد زیر باشند:

- اطلاعات بالینی به‌همراه RNA expression؛
- اطلاعات بالینی به‌همراه RNA expression و DNA methylation؛
- یا ترکیب دیگری از داده‌های عمومی پروژه که از نظر سؤال آماری توجیه شده باشد و پیش از استفاده به تأیید تیم دستیاری برسد.

استفاده‌ی صرف از متغیرهای بالینی، بدون واردکردن واقعی داده‌ی مولکولی، الزامات مسیر ب را کامل نمی‌کند و مشمول ۱۰ امتیاز اضافه نخواهد بود. از طرف دیگر، هدف پروژه آزمون‌کردن بی‌برنامه‌ی هزاران ژن یا ساخت مدل‌های بسیار پیچیده نیست. در مسائل با ابعاد بالا باید از تعداد محدودی ویژگی ازپیش توجیه‌شده، خلاصه‌سازی در سطح مسیرهای زیستی یا کاهش بعدی که با محتوای درس سازگار باشد استفاده شود.

> برای این پروژه فقط فایل‌ها و داده‌های **عمومی و بدون محدودیت دسترسی** در GDC مجاز هستند. داده‌های controlled-access که نیاز به مجوز جداگانه دارند خارج از دامنه‌ی پروژه‌اند. واحد اصلی تحلیل باید در سطح بیمار تعریف شود؛ بنابراین شناسه‌های نمونه و فایل‌های مختلف باید به شناسه‌ی بیمار نگاشت شوند و یک بیمار نباید بدون دلیل آماری چند بار به‌عنوان مشاهده‌ی مستقل وارد تحلیل شود.

دسترسی رسمی:

- صفحه‌ی پروژه: GDC - TCGA-BRCA Project
- درگاه اصلی داده: NCI Genomic Data Commons Data Portal

مسیر ج: NACC Alzheimer's Data

مسیر چندوجهی MRI + UDS ـ حداکثر ۱۱۰ امتیاز؛ شامل ۱۰ امتیاز اضافه

NACC یا National Alzheimer's Coordinating Center یکی از منابع مهم داده برای مطالعه‌ی بیماری آلزایمر و اختلالات شناختی است. داده‌های این مرکز در سطح شرکت‌کننده و مراجعه سازمان‌دهی می‌شوند و می‌توانند اطلاعات جمعیت‌شناختی، سابقه‌ی پزشکی، وضعیت عملکردی، آزمون‌های شناختی و عصب‌روان‌شناختی، تشخیص‌های بالینی و برای بخشی از افراد داده‌های تصویربرداری مغزی را شامل شوند.

در این درس، دانشجویان مسیر ج با کل پایگاه NACC کار نخواهند کرد. **تیم دستیاری یک زیرمجموعه‌ی آماده و ازپیش تعیین‌شده از NACC در اختیار دانشجویان قرار می‌دهد.** این زیرمجموعه به‌طور مشخص چندوجهی است و شامل دو بخش زیر خواهد بود:

- **UDS**: متغیرهای منتخب از Uniform Data Set شامل اطلاعات جمعیت‌شناختی، پزشکی، عملکردی، شناختی و تشخیصی؛
- **MRI**: متغیرها، اندازه‌گیری‌ها یا ویژگی‌های تصویربرداری تشدید مغناطیسی متناظر با شرکت‌کنندگان موجود در همان زیرمجموعه، همراه با شناسه‌ها و فراداده‌های لازم برای اتصال به UDS.

استفاده از هر دو بخش UDS و MRI برای دانشجویان مسیر ج الزامی است. تحلیل صرف UDS بدون استفاده‌ی واقعی از متغیرهای MRI، الزامات مسیر ج را کامل نمی‌کند و مشمول ۱۰ امتیاز اضافه نخواهد بود. تیم دستیاری همراه با زیرمجموعه، فایل راهنمای متغیرها، کلیدهای اتصال و توضیح ساختار فایل‌ها را نیز ارائه خواهد کرد.

در تمام فازها باید مشخص باشد هر سطر نماینده‌ی چه واحدی است، اتصال UDS و MRI چگونه انجام شده، چند شرکت‌کننده پیش و پس از اتصال باقی مانده‌اند و داده‌های گمشده در هر وجه چه الگویی دارند. چون ممکن است برای یک شرکت‌کننده چند مراجعه ثبت شده باشد، استقلال مشاهدات باید صریحاً کنترل شود. مگر آن‌که تیم درس روش دیگری را تأیید کند، تحلیل‌های اصلی استنباطی باید بر یک مشاهده‌ی مستقل به ازای هر شرکت‌کننده استوار باشند.

مستندات عمومی NACC:

- معرفی داده‌ها: NACC - About NACC Data
- فرم‌ها و مستندات: NACC - Data Forms and Documentation
- راهنمای پژوهشگر: NACC - Researcher Guide

۳. زمان‌بندی و ساختار نمره

زمان‌بندی فازها برای هر سه مسیر یکسان است. ارزیابی پروژه در مسیر الف روی مقیاس ۱۰۰ **امتیاز** انجام می‌شود. در مسیرهای ب و ج، در صورت انجام کامل و صحیح الزامات ویژه‌ی همان مسیر، ۱۰ **امتیاز اضافه** در نظر گرفته می‌شود؛ بنابراین سقف امتیاز این دو مسیر ۱۱۰ است.

فاز	بازه‌ی انجام	امتیاز پایه
Phase 1	۱۸ مهر تا ۱۲ آبان	۱۲٫۵
Phase 2	۱۲ آبان تا ۲۷ آبان	۱۵٫۵
Phase 3	۲۸ آبان تا ۲۷ آذر	۲۲
Phase 4	۲۷ آذر تا ۱۵ دی	۲۵
Phase 5	۱۵ دی تا ۵ بهمن	۲۵
مجموع امتیاز پایه	--	۱۰۰

تمامی ددلاین‌های پروژه قطعی هستند و تحت هیچ شرایطی تمدید نخواهند شد. هیچ تمدیدی برای هیچ‌یک از فازها در نظر گرفته نمی‌شود.

- Dataset A: حداکثر ۱۰۰ **امتیاز**؛
- Dataset B: حداکثر ۱۱۰ **امتیاز**؛ شامل ۱۰۰ امتیاز پایه و حداکثر ۱۰ امتیاز برای انجام صحیح تحلیل چندوجهی TCGA-BRCA با حداقل دو نوع داده‌ی واقعی؛
- Dataset C: حداکثر ۱۱۰ **امتیاز**؛ شامل ۱۰۰ امتیاز پایه و حداکثر ۱۰ امتیاز برای انجام صحیح الزامات چندوجهی UDS + MRI در زیرمجموعه‌ی NACC ارائه‌شده توسط تیم دستیاری.

صرف انتخاب مسیر ب یا ج باعث دریافت ۱۰ امتیاز اضافه نمی‌شود. این امتیاز فقط زمانی تعلق می‌گیرد که تسک‌های ویژه‌ی همان مسیر کامل، صحیح، قابل بازتولید و در جلسه‌ی دفاع قابل توضیح باشند.

۴. ثبت موضوع و کارت پروژه

در ابتدای فاز اول، هر دانشجو باید فایل `PROJECT_CARD.md` را در مخزن خود ایجاد کند. این کارت برای مشخص‌کردن چارچوب آماری پروژه است و لازم نیست از همان ابتدا تمام جزئیات تحلیل نهایی مشخص باشند.

مجموعه‌داده و زیرمجموعه‌ی مورد استفاده. نام مسیر و دقیقاً فایل‌ها، دوره‌ها یا زیرمجموعه‌هایی را که قرار است بررسی کنید بنویسید. اگر هنوز انتخاب متغیرها نهایی نیست، دامنه‌ی اولیه را مشخص کنید.

عنوان موقت پروژه. یک عنوان کوتاه بنویسید که موضوع آماری پروژه را بیان کند، نه نتیجه‌ای را که انتظار دارید به دست آید.

سؤال آماری اصلی. سؤال باید مشخص کند چه چیزی قرار است توصیف، مقایسه یا بررسی شود. سؤال‌های بسیار کلی مانند «بررسی داده‌ی سلامت» پذیرفته نیستند.

واحد مشاهده و جمعیت قابل تفسیر. مشخص کنید هر ردیف یا هر واحد تحلیل نماینده‌ی چه چیزی است: فرد، بیمار، نمونه‌ی زیستی، مراجعه یا واحد دیگر. همچنین توضیح دهید نتایج شما درباره‌ی چه جمعیتی قابل تفسیر هستند.

متغیرهای اصلی و مقیاس اندازه‌گیری. متغیرهای مهم را فهرست کنید و نوع آن‌ها را مشخص کنید: کمی پیوسته، کمی گسسته، اسمی، ترتیبی یا دودویی.

نقش متغیرها در سؤال. اگر سؤال شما رابطه‌ای یا مقایسه‌ای است، متغیر پاسخ و متغیرهای توضیحی یا متغیر گروه‌بندی را مشخص کنید. اگر در این مرحله متغیر پاسخ معنا ندارد، دلیل آن را توضیح دهید.

نوع سؤال. مشخص کنید سؤال شما عمدتاً توصیفی، مقایسه‌ای، ارتباطی یا پیش‌بینی‌محور است. برای این درس سؤال‌های توصیفی، مقایسه‌ای و ارتباطی در اولویت هستند.

فرضیه‌ی اولیه، در صورت وجود. اگر سؤال از ابتدا قابلیت آزمون فرض دارد، فرضیه‌ی علمی اولیه را با زبان روشن بنویسید. لازم نیست هنوز فرمول دقیق فرض صفر و مقابل را ارائه کنید؛ آن بخش در فاز سوم کامل می‌شود.

محدودیت‌های اولیه. حداقل دو محدودیت قابل پیش‌بینی، مانند نمونه‌گیری، داده‌ی گمشده، اندازه‌ی زیرگروه‌ها، تکرار مشاهدات یا کیفیت اندازه‌گیری را ثبت کنید.

سؤال‌ها در یک فهرست مرکزی ثبت خواهند شد تا احتمال تکرار غیرعادی پروژه‌ها کاهش یابد. تغییر معنادار سؤال اصلی پس از پایان فاز اول باید با تیم دستیاری هماهنگ شود.

۵. فاز اول ـ شناخت مطالعه، داده و آمار توصیفی

بازه: ۱۸ مهر تا ۱۲ آبان **امتیاز: ۱۲٫۵ از ۱۰۰**

هدف فاز اول این است که قبل از هر استنباط، دقیقاً بفهمید داده از کجا آمده، واحد مشاهده چیست، چه نوع مطالعه‌ای با آن انجام می‌دهید و توزیع متغیرهای اصلی چگونه است. این فاز با مباحث ابتدایی کتاب درباره‌ی ماهیت آمار، نمونه‌گیری، مطالعه‌ی مشاهده‌ای و آمار توصیفی هم‌راستاست.

تسک‌های مشترک

۱. **منشأ داده و سازوکار جمع‌آوری.** منبع رسمی داده، دوره‌ی جمع‌آوری، روش کلی تولید داده و هر محدودیت دسترسی را توضیح دهید. مشخص کنید داده حاصل پیمایش، مطالعه‌ی مشاهده‌ای، مراجعه‌ی بالینی، تصویربرداری یا سازوکار دیگری است.

۲. **واحد مشاهده و ساختار داده.** توضیح دهید یک ردیف داده نماینده‌ی چیست و آیا برای یک فرد چند ردیف یا چند مشاهده وجود دارد. اگر ساختار سلسله‌مراتبی یا تکرارشونده وجود دارد، آن را با یک شکل یا جدول ساده نشان دهید.

۳. **نمونه‌گیری، انتخاب و قابلیت تعمیم.** بررسی کنید افراد یا واحدهای موجود در داده چگونه انتخاب شده‌اند. مشخص کنید آیا نمونه‌گیری تصادفی است، آیا مطالعه مشاهده‌ای است، و تا چه حد می‌توان نتایج را به جمعیتی بزرگ‌تر تعمیم داد.

۴. **طبقه‌بندی متغیرها.** برای متغیرهای اصلی، نوع و مقیاس اندازه‌گیری را مشخص کنید. این طبقه‌بندی باید در انتخاب خلاصه‌های آماری، نمودار و روش‌های مراحل بعد استفاده شود.

۵. **ممیزی کیفیت داده.** داده‌های گمشده، مقادیر غیرممکن، کدهای ویژه‌ی «نامعلوم یا پاسخ نداده»، رکوردهای تکراری و ناسازگاری‌های منطقی را بررسی کنید. برای هر مورد تصمیم بگیرید در تحلیل چگونه با آن برخورد خواهید کرد و دلیل تصمیم را بنویسید.

۶. **جدول‌های فراوانی و توزیع تجربی.** برای متغیرهای طبقه‌ای جدول فراوانی و درصد و برای متغیرهای کمی خلاصه‌ی توزیع را ارائه کنید. هدف فقط تولید جدول نیست؛ باید توضیح دهید کدام الگوها مهم‌اند.

۷. **مرکز و پراکندگی.** برای متغیرهای کمی، میانگین، میانه، انحراف معیار، چارک‌ها و دامنه‌ی بین‌چارکی را در موارد مناسب گزارش کنید و توضیح دهید چرا هر معیار برای آن متغیر مناسب یا نامناسب است.

۸. **مصورسازی درست.** حداقل چهار نمودار معنادار تولید کنید. نوع نمودار باید با نوع متغیر سازگار باشد. محور، واحد و عنوان باید کامل باشند و از نمودارهای گمراه‌کننده، برش نامناسب محور یا نمایش‌های غیرضروری

سه‌بعدی اجتناب شود.

۹. مقایسه‌ی توصیفی اولیه. حداقل یک متغیر کمی یا طبقه‌ای را بین دو یا چند گروه به‌صورت صرفاً توصیفی مقایسه کنید. در این فاز هنوز ادعای استنباطی نکنید.

۱۰. نهایی‌کردن سؤال آماری. با توجه به شناخت حاصل از داده، سؤال اصلی را نهایی یا محدودتر کنید و توضیح دهید چرا داده‌ی موجود برای پاسخ‌دادن به آن مناسب است.

الزامات ویژه‌ی مسیر الف: NHANES

الف۱. شناسایی فایل‌ها و کلید ادغام. فایل‌های مورد استفاده و متغیر شناسه‌ی مشترک را معرفی کنید و نشان دهید ادغام فایل‌ها چگونه انجام شده است. تعداد افراد قبل و بعد از ادغام گزارش شود.

الف۲. شناسایی وزن و طرح نمونه‌گیری. متغیرهای وزن مناسب برای بخش‌های مورد استفاده را شناسایی کنید و در حد محتوای درس توضیح دهید چرا هر فرد در **NHANES** نماینده‌ی تعداد متفاوتی از افراد جمعیت است.

الف۳. مقایسه‌ی خلاصه‌ی خام و وزن‌دار. برای حداقل یک میانگین یا نسبت، خلاصه‌ی ساده و خلاصه‌ی وزن‌دار را کنار هم گزارش کنید و درباره‌ی تفاوت آن‌ها بحث کنید. این بخش برای درک اثر نمونه‌گیری است، نه برای ورود به جزئیات نظری پیمایش‌های پیچیده.

الف۴. تعریف جمعیت تحلیلی. معیارهای ورود و خروج مانند بازه‌ی سنی و نیاز به موجودبودن متغیرهای اصلی را دقیق بنویسید و تعداد افراد حذف‌شده در هر مرحله را گزارش کنید.

الزامات ویژه‌ی مسیر ب: TCGA-BRCA

ب۱. تعیین انواع داده و واحد تحلیل. حداقل دو نوع داده‌ای را که در پروژه استفاده می‌کنید دقیقاً نام ببرید و مشخص کنید هر فایل در چه سطحی ذخیره شده است؛ برای مثال بیمار، نمونه‌ی بافتی یا اندازه‌گیری مولکولی. سپس توضیح دهید واحد اصلی تحلیل چرا باید در سطح بیمار تعریف شود.

ب۲. تطبیق شناسه‌ها بین انواع داده. شناسه‌های نمونه و بیمار را بین فایل‌های بالینی و مولکولی تطبیق دهید. تعداد رکوردهای اولیه، تعداد بیماران یکتا در هر نوع داده، تعداد بیماران مشترک و حجم نمونه‌ی نهایی پس از ادغام را در یک جدول جریان داده گزارش کنید. هر حذف یا عدم تطابق باید قابل ردیابی باشد.

ب۳. ممیزی جداگانه‌ی داده‌ی بالینی و مولکولی. متغیرهای بالینی و مولکولی را جداگانه ممیزی کنید. برای هر بخش نوع متغیر، دامنه، داده‌ی گمشده، مقادیر غیرممکن و خلاصه‌های توصیفی مناسب را ارائه کنید تا کیفیت هر وجه پیش از ادغام روشن باشد.

ب۴. بررسی الگوی نبودن انواع داده. بررسی کنید چه تعداد بیمار فقط داده‌ی بالینی، فقط یک وجه مولکولی یا هر دو وجه مورد نیاز را دارند. مشخص کنید تحلیل اصلی روی چه زیرنمونه‌ای انجام می‌شود و آیا بیماران دارای داده‌ی چندوجهی از نظر چند متغیر بالینی مهم با سایر بیماران تفاوت توصیفی دارند.

ب۵. توصیف ویژگی‌های مولکولی یا امتیازهای مسیر زیستی. چند ویژگی مولکولی محدود و ازپیش توجیه‌شده یا چند امتیاز خلاصه در سطح مسیر زیستی انتخاب کنید و توزیع، مرکز، پراکندگی، نقاط دورافتاده و داده‌ی گمشده‌ی آن‌ها را گزارش کنید. آزمون‌کردن هزاران ویژگی خام بدون طرح آماری مشخص در این مرحله قابل قبول نیست.

الزامات ویژه‌ی مسیر ج: NACC

ج۱. نقشه‌ی زیرمجموعه‌ی UDS و MRI. فایل‌های UDS و MRI تحویلی تیم دستیاری را معرفی و متغیرهای هر بخش را دسته‌بندی کنید. برای UDS مشخص کنید کدام متغیرها جمعیت‌شناختی، پزشکی، عملکردی یا شناختی هستند و برای MRI توضیح دهید هر متغیر چه اندازه‌گیری یا ویژگی تصویربرداری را نمایش می‌دهد.

ج۲. ساختار شرکت‌کننده و مراجعه. تعداد شرکت‌کنندگان یکتا، تعداد مراجعه‌ها و توزیع تعداد مراجعه به ازای هر شرکت‌کننده را گزارش کنید. سپس قاعده‌ی انتخاب مشاهده‌ی اصلی را برای فازهای بعدی مشخص کنید تا یک فرد چند بار به‌عنوان مشاهده‌ی مستقل وارد تحلیل نشود.

ج۳. اتصال UDS و MRI. با استفاده از شناسه‌ها و قواعد اعلام‌شده همراه داده، دو وجه را به هم متصل کنید. تعداد افراد در هر فایل، تعداد افراد مشترک، موارد بدون تطابق و حجم نمونه‌ی نهایی چندوجهی را شفاف گزارش کنید.

ج۴. داده‌های گمشده و انتخاب‌شدن نمونه‌ی چندوجهی. برای متغیرهای اصلی هر دو وجه درصد گمشدگی را گزارش کنید و بررسی کنید آیا افراد دارای MRI از نظر چند متغیر مهم UDS با دیگر افراد زیرمجموعه تفاوت توصیفی دارند.

ج۵. خلاصه‌ی مشترک شناختی و تصویربرداری. حداقل یک نمره‌ی شناختی یا بالینی از UDS و حداقل یک متغیر کمی از MRI را با جدول و نمودار مناسب توصیف کنید و دامنه، مرکز، پراکندگی و نقاط غیرعادی را گزارش دهید.

خروجی فاز اول: `reports/phase1.pdf`، فایل `PROJECT_CARD.md`، کدهای قابل بازتولید، `README.md` به‌روزشده و برچسب `phase-1`.

۶. فاز دوم ـ احتمال و توزیع‌های احتمالی

بازه: ۱۲ آبان تا ۲۷ آبان **امتیاز: ۱۵۵ از ۱۰۰**

در این فاز داده‌ی واقعی را به زبان احتمال ترجمه می‌کنید. تمرکز روی احتمال شرطی، استقلال، متغیرهای تصادفی، امید ریاضی، واریانس و توزیع‌های دوجمله‌ای و نرمال است. **بازنمونه‌گیری و bootstrap در این فاز الزام نیستند** و در فاز سوم، در جایگاه درست خود کنار فاصله‌ی اطمینان قرار می‌گیرند.

تسک‌های مشترک

۱. تعریف رویدادها و متغیرهای تصادفی. حداقل دو رویداد و یک متغیر تصادفی مرتبط با سؤال پروژه تعریف

کنید. باید دقیقاً روشن باشد هر رویداد یا مقدار متغیر به چه مشاهده‌ای در داده مربوط است.

۲. احتمال‌های حاشیه‌ای و مشترک. برای دو رویداد طبقه‌ای، احتمال تجربی هر رویداد و احتمال وقوع هم‌زمان آن‌ها را محاسبه و تفسیر کنید.

۳. احتمال شرطی. حداقل دو احتمال شرطی محاسبه کنید و توضیح دهید چگونه شرط‌کردن روی یک گروه یا ویژگی، احتمال رویداد مورد نظر را تغییر می‌دهد.

۴. بررسی مفهوم استقلال. برای یک جفت متغیر یا رویداد مناسب بررسی کنید آیا داده با فرض استقلال سازگار به نظر می‌رسد یا خیر. در این فاز هدف استدلال احتمالی است و الزاماً آزمون رسمی استقلال انجام نمی‌شود.

۵. توزیع گسسته و مدل دوجمله‌ای. یک شمارش یا رویداد دودویی مناسب تعریف کنید و بررسی کنید در چه شرایطی مدل دوجمله‌ای می‌تواند تقریب معقولی باشد. اگر فرض‌های دوجمله‌ای برقرار نیستند، دقیقاً دلیل آن را توضیح دهید.

۶. متغیر پیوسته و توزیع نرمال. برای یک متغیر کمی، شکل توزیع را با هیستوگرام و نمودار مناسب بررسی کنید و درباره‌ی مناسب‌بودن یا نبودن تقریب نرمال بحث کنید. صرف گزارش آزمون نرمال‌بودن کافی نیست.

۷. امید ریاضی و واریانس. برای حداقل یک متغیر یا توزیع تجربی، میانگین و واریانس را محاسبه کنید و معنای آن‌ها را در متن مسئله توضیح دهید.

۸. دو متغیر تصادفی و کوواریانس. برای دو متغیر کمی مناسب، نمودار پراکنش، کوواریانس و جهت رابطه را بررسی کنید. همبستگی رسمی و استنباط پیرامون آن در فاز چهارم کامل‌تر خواهد شد.

۹. قضیه‌ی بیز، در صورت تناسب. اگر سؤال شما دارای ساختار مناسب برای به‌روزرسانی احتمال است، یک محاسبه‌ی ساده‌ی بیزی با استفاده از فراوانی‌های تجربی انجام دهید. اگر ساختار مسئله مناسب نیست، این تسک با تأیید تیم دستیاری می‌تواند با یک تمرین احتمال هم‌ارز جایگزین شود.

الزامات ویژه‌ی مسیر الف: NHANES

الف۱. احتمال شرطی در زیرگروه‌ها. برای یک پیامد دودویی، احتمال وقوع آن را در حداقل دو زیرگروه مانند گروه‌های سنی یا جنس گزارش کنید. تفاوت احتمال‌ها فقط توصیف می‌شود و هنوز آزمون فرض انجام نمی‌شود.

الف۲. مدل دوجمله‌ای برای یک شمارش. یک رویداد مشخص مانند عبور از یک آستانه‌ی بالینی تعریف کنید و رفتار شمارش آن را در زیرنمونه‌های هم‌اندازه با مدل دوجمله‌ای مقایسه کنید.

الف۳. شکل توزیع یک اندازه‌گیری سلامت. یک متغیر کمی مانند فشارخون، شاخص بدنی یا یک شاخص آزمایشگاهی را انتخاب کنید و درباره‌ی چولگی، نقاط دورافتاده و تقریب نرمال آن بحث کنید.

الف۴. نقش وزن‌های نمونه‌گیری در احتمال تجربی. برای یک نسبت، نسخه‌ی بدون وزن و وزن‌دار را مقایسه کنید و توضیح دهید چرا «فراوانی در نمونه» لزوماً با «برآورد احتمال در جمعیت» یکسان نیست.

الزامات ویژه‌ی مسیر ب: TCGA-BRCA

ب۱. توزیع یک نشانگر یا امتیاز مولکولی. یک ویژگی مولکولی محدود یا امتیاز مسیر زیستی را به‌عنوان متغیر تصادفی کمی انتخاب کنید و شکل توزیع، میانگین، واریانس و نقاط دورافتاده‌ی آن را بررسی کنید.

ب۲. احتمال شرطی یک ویژگی بالینی یا زیرنوع. یک رویداد بالینی یا زیرنوع ازپیش تعریف‌شده را انتخاب کنید و احتمال آن را در گروه‌هایی که با یک نشانگر یا امتیاز مولکولی تعریف شده‌اند محاسبه کنید. گروه‌بندی باید با قاعده‌ای روشن و قبل از مشاهده‌ی نتیجه مشخص شود.

ب۳. احتمال مشترک بین دو وجه داده. برای یک متغیر طبقه‌ای بالینی و یک متغیر مولکولی دسته‌بندی‌شده، احتمال‌های حاشیه‌ای، احتمال مشترک و حداقل یک احتمال شرطی را محاسبه کنید و درباره‌ی استقلال یا وابستگی احتمالی آن‌ها بحث کنید.

ب۴. ارتباط دو متغیر کمی از دو وجه. یک متغیر کمی بالینی و یک متغیر کمی مولکولی انتخاب کنید و نمودار پراکنش، کوواریانس و جهت رابطه را گزارش کنید. در این فاز هنوز استنباط رسمی همبستگی انجام نمی‌شود.

ب۵. کنترل استقلال در سطح بیمار. تمام محاسبات اصلی این فاز باید در سطح بیمار انجام شوند. اگر برای یک بیمار چند نمونه یا اندازه‌گیری مولکولی وجود دارد، یک قاعده‌ی شفاف برای انتخاب یا خلاصه‌سازی تعریف کنید.

الزامات ویژه‌ی مسیر ج: NACC

ج۱. احتمال شرطی وضعیت شناختی. یک وضعیت تشخیصی یا شناختی از UDS تعریف کنید و احتمال آن را در حداقل دو گروه محاسبه کنید. حداقل یکی از گروه‌بندی‌ها باید با یک متغیر MRI یا ترکیبی از UDS و MRI ساخته شود.

ج۲. توزیع یک نمره‌ی شناختی و یک متغیر MRI. یک نمره‌ی کمی شناختی از UDS و یک متغیر کمی از MRI انتخاب کنید و برای هر دو شکل توزیع، میانگین، واریانس و نقاط دورافتاده را گزارش کنید.

ج۳. احتمال مشترک دو وجه. یک رویداد از UDS و یک رویداد ساخته‌شده از MRI تعریف کنید و احتمال حاشیه‌ای، مشترک و شرطی آن‌ها را محاسبه کنید.

ج۴. کوواریانس شناخت و تصویربرداری. یک متغیر کمی شناختی یا بالینی و یک متغیر کمی MRI انتخاب کنید و نمودار پراکنش، کوواریانس و جهت رابطه را گزارش کنید. از این رابطه نتیجه‌ی علّی نگیرید.

ج۵. کنترل مراجعه‌های تکراری. محاسبات اصلی باید بر یک مشاهده‌ی مستقل به ازای هر شرکت‌کننده استوار باشند. قاعده‌ی انتخاب مراجعه‌ی شاخص را دقیق مستند کنید.

خروجی فاز دوم: `reports/phase2.pdf`، کد تحلیل احتمال، جدول‌ها و شکل‌های نهایی و برچسب `phase-2`.

۷. فاز سوم ـ نمونه‌گیری، برآورد و استنباط آماری

بازه: ۲۸ آبان تا ۲۷ آذر **امتیاز: ۲۲ از ۱۰۰**

در این فاز از آمار توصیفی و احتمال به استنباط درباره‌ی پارامترهای جمعیت می‌رسید. انتخاب روش باید با نوع متغیر، طرح داده و سؤال پروژه سازگار باشد.

تسک‌های مشترک

۱. پارامتر و برآوردگر. برای دست‌کم دو کمیت اصلی، مشخص کنید پارامتر جمعیت چیست و چه آماره‌ای از نمونه برای برآورد آن استفاده می‌کنید.

۲. توزیع نمونه‌گیری و خطای استاندارد. با شبیه‌سازی یا بازنمونه‌گیری نشان دهید که یک آماره مانند میانگین یا نسبت در نمونه‌های مختلف تغییر می‌کند و مفهوم خطای استاندارد را در متن داده توضیح دهید.

۳. فاصله‌ی اطمینان یک پارامتر. حداقل یک فاصله‌ی اطمینان برای یک میانگین یا نسبت بسازید و تفسیر درست فراوانی‌گرای آن را بنویسید.

۴. مقایسه‌ی دو گروه. حداقل یک فاصله‌ی اطمینان برای تفاوت دو میانگین یا دو نسبت ارائه کنید. مستقل یا جفت‌شده‌بودن داده باید به‌درستی تشخیص داده شود.

۵. آزمون فرض. حداقل دو آزمون فرض مرتبط با سؤال اصلی اجرا کنید. پیش از محاسبه باید فرض صفر، فرض مقابل، سطح معنی‌داری و فرض‌های روش مشخص باشند.

۶. تفسیر مقدار p-value. مقدار p-value را به زبان مسئله تفسیر کنید. جملاتی مانند «احتمال درست‌بودن فرض صفر برابر p-value است» نادرست هستند.

۷. Bootstrap و فاصله‌ی اطمینان. برای یک کمیت که ساخت فاصله‌ی اطمینان تحلیلی آن دشوارتر یا توزیع آن نامتقارن است، فاصله‌ی اطمینان bootstrap بسازید و با روش استاندارد مقایسه کنید.

۸. تحلیل واریانس، در صورت تناسب. اگر سؤال شامل مقایسه‌ی میانگین یک متغیر کمی در سه یا چند گروه است، یک ANOVA یک‌طرفه انجام دهید، پیش‌فرض‌ها را بررسی کنید و نتیجه را تفسیر کنید. اگر چنین ساختاری در پروژه وجود ندارد، با تأیید تیم درس یک تحلیل استنباطی هم‌سطح جایگزین می‌شود.

۹. اندازه‌ی اثر و اهمیت عملی. در کنار معنی‌داری آماری، اندازه‌ی تفاوت یا اثر را گزارش کنید. نتیجه‌ای با p-value کوچک اما اثر بسیار ناچیز باید به همین صورت توصیف شود.

الزامات ویژه‌ی مسیر الف: NHANES

الف۱. برآورد جمعیتی وزن‌دار. برای حداقل یک میانگین یا نسبت، برآورد و فاصله‌ی اطمینان را با درنظرگرفتن وزن مناسب گزارش کنید. اگر پیاده‌سازی کامل طرح پیچیده فراتر از کدهای کلاس است، تیم دستیاری الگوی اجرایی مناسب ارائه خواهد کرد.

الف۲. مقایسه‌ی دو گروه. یک مقایسه‌ی معنادار بین دو گروه انجام دهید و علاوه بر آزمون، فاصله‌ی اطمینان تفاوت و اندازه‌ی اثر را گزارش کنید.

الف۳. مقایسه‌ی چند گروه. اگر متغیر گروه‌بندی سه سطح یا بیشتر دارد، از ANOVA یا روش تدریس‌شده‌ی

مناسب استفاده کنید و تفاوت بین «وجود تفاوت کلی» و «محل دقیق تفاوت» را توضیح دهید.

الزامات ویژه‌ی مسیر ب: TCGA-BRCA

ب۱. برآورد و فاصله‌ی اطمینان برای یک کمیت مولکولی. برای یک ویژگی مولکولی یا امتیاز مسیر زیستی ازپیش تعیین‌شده، یک کمیت اصلی را برآورد کنید و فاصله‌ی اطمینان مناسب ارائه دهید. اگر توزیع نامتقارن است، روش استاندارد و bootstrap در سطح بیمار را مقایسه کنید.

ب۲. مقایسه‌ی یک کمیت مولکولی بین گروه‌های بالینی. حداقل یک مقایسه‌ی استنباطی انجام دهید که واقعاً داده‌ی مولکولی را به یک گروه‌بندی بالینی متصل کند. فاصله‌ی اطمینان تفاوت، آزمون مناسب و اندازه‌ی اثر را گزارش کنید.

ب۳. آزمون‌های متعدد و کنترل نرخ کشف کاذب. اگر چند ویژگی هم‌زمان بررسی می‌شوند، دامنه‌ی ویژگی‌ها و راهبرد آزمون‌های متعدد را از قبل مشخص کنید. در صورت نیاز از روشی مانند Benjamini--Hochberg استفاده کنید و تفاوت مقدار p-value خام و تعدیل‌شده را توضیح دهید.

ب۴. تحلیل در سطح مسیر زیستی یا مجموعه‌ی محدود ویژگی‌ها. آزمون‌کردن هزاران ژن بدون طرح آماری مشخص قابل قبول نیست. برای این درس تحلیل یک مجموعه‌ی کوچک از ویژگی‌های ازپیش توجیه‌شده یا خلاصه‌سازی در سطح مسیرهای زیستی مناسب‌تر است.

ب۵. بازنمونه‌گیری در سطح بیمار. در هر تحلیل bootstrap یا بازنمونه‌گیری، بیمار واحد بازنمونه‌گیری است. نمونه‌ها یا فایل‌های متعدد متعلق به یک بیمار نباید مستقل از یکدیگر بازنمونه‌گیری شوند.

الزامات ویژه‌ی مسیر ج: NACC

ج۱. انتخاب یک مشاهده‌ی مستقل برای هر شرکت‌کننده. تحلیل اصلی استنباطی باید طوری ساخته شود که یک فرد چند بار به‌عنوان مشاهده‌ی مستقل وارد نشود. اگر از دو زمان برای یک فرد استفاده می‌کنید، ساختار جفت‌شده باید صریحاً تعریف شود.

ج۲. فاصله‌ی اطمینان برای یک نمره‌ی UDS و یک شاخص MRI. برای یک نمره‌ی شناختی یا بالینی و یک متغیر تصویربرداری، برآورد نقطه‌ای و فاصله‌ی اطمینان مناسب ارائه کنید و تفاوت مقیاس و عدم قطعیت آن‌ها را توضیح دهید.

ج۳. مقایسه‌ی چندوجهی بین گروه‌ها. حداقل یک تحلیل استنباطی باید هر دو وجه را درگیر کند؛ برای مثال مقایسه‌ی یک شاخص MRI میان گروه‌های شناختی تعریف‌شده با UDS یا مقایسه‌ی یک نمره‌ی شناختی میان گروه‌هایی که با یک شاخص MRI تعریف شده‌اند. فاصله‌ی اطمینان و اندازه‌ی اثر نیز گزارش شود.

ج۴. تحلیل واریانس، در صورت تناسب. اگر سه یا چند گروه شناختی یا تشخیصی مناسب در UDS وجود دارد، یک متغیر کمی MRI یا شناختی را با ANOVA یک‌طرفه مقایسه کنید و پیش‌فرض‌ها را بررسی کنید.

ج۵. Bootstrap در سطح شرکت‌کننده. برای یک کمیت چندوجهی یا تفاوت گروهی، فاصله‌ی اطمینان bootstrap بسازید. واحد بازنمونه‌گیری باید شرکت‌کننده باشد و متغیرهای UDS و MRI همان فرد با هم

بازنمونه‌گیری شوند.

خروجی فاز سوم: `reports/phase3.pdf`، کدهای استنباط، جدول آزمون‌ها و فاصله‌های اطمینان، و برچسب `phase-3`.

۸. فاز چهارم ـ رگرسیون، همبستگی و تشخیص مدل

بازه: ۲۷ آذر تا ۱۵ دی **امتیاز: ۲۵ از ۱۰۰**

این فاز مستقیماً بر بخش رگرسیون کتاب استوار است. روش‌های اصلی این فاز **رگرسیون خطی ساده و چندگانه** و ابزارهای تشخیصی مرتبط هستند. رگرسیون لجستیک، GLM و مدل‌های منظم‌شده جزو الزامات این فاز نیستند.

تسک‌های مشترک

۱. **تعریف پاسخ و متغیرهای توضیحی.** یک متغیر پاسخ کمی و مجموعه‌ی محدودی از متغیرهای توضیحی را تعریف کنید. دلیل انتخاب هر متغیر باید به سؤال پروژه مرتبط باشد.

۲. **برازش خط با کمترین مربعات.** برای یک متغیر توضیحی کمی، نمودار پراکنش و خط کمترین مربعات را ارائه کنید و شیب و عرض از مبدأ را در واحدهای واقعی مسئله تفسیر کنید.

۳. **رگرسیون خطی ساده.** مدل ساده را برازش کنید، فاصله‌ی اطمینان شیب و آزمون مرتبط را گزارش کنید و تفاوت «وجود رابطه‌ی خطی» با «رابطه‌ی علّی» را توضیح دهید.

۴. **رگرسیون چندگانه.** حداقل یک مدل چندگانه با تعداد معقولی متغیر توضیحی بسازید و ضرایب را با ثابت‌نگه‌داشتن سایر متغیرها تفسیر کنید. ورود متغیرها باید بر اساس سؤال و منطق علمی باشد، نه جست‌وجوی خودکار برای کوچک‌ترین p-value.

۵. **مقایسه‌ی مدل ساده و چندگانه.** بررسی کنید با افزودن متغیرهای مرتبط، ضریب متغیر اصلی، R^2 و خطای باقیمانده چگونه تغییر می‌کنند. درباره‌ی علت احتمالی این تغییر توضیح دهید.

۶. **متغیرهای صفر و یک.** حداقل یک متغیر طبقه‌ای مناسب را با کدگذاری صفر و یک وارد یک مدل رگرسیونی کنید و تفسیر ضریب آن را نشان دهید.

۷. **بررسی باقیمانده‌ها.** نمودار باقیمانده در برابر مقدار برازش‌شده و حداقل یک نمودار تشخیصی دیگر تولید کنید. خطی‌بودن، تغییر واریانس و نقاط اثرگذار یا دورافتاده را بررسی کنید.

۸. **تبدیل یا شکل غیرخطی ساده، در صورت نیاز.** اگر نمودارها رابطه‌ی غیرخطی یا واریانس نامناسب را نشان می‌دهند، یک تبدیل منطقی مانند لگاریتم را بررسی کنید و مدل قبل و بعد را مقایسه کنید. تبدیل فقط زمانی انجام شود که دلیل روشن داشته باشد.

۹. **فاصله‌ی اطمینان و فاصله‌ی پیش‌بینی.** برای یک مقدار معنادار از متغیرهای توضیحی، فاصله‌ی اطمینان برای میانگین پاسخ و فاصله‌ی پیش‌بینی برای مشاهده‌ی جدید را ارائه کنید و تفاوت آن‌ها را توضیح دهید.

۱۰. **همبستگی و رگرسیون.** ضریب همبستگی را برای یک جفت متغیر کمی گزارش و با نتیجه‌ی رگرسیون

ساده مقایسه کنید. تأکید کنید که همبستگی، حتی اگر قوی باشد، به‌تنهایی علت را اثبات نمی‌کند.

۱۱. چندهم‌خطی. در مدل چندگانه بررسی کنید آیا متغیرهای توضیحی به‌شدت با یکدیگر مرتبط‌اند. اثر چندهم‌خطی بر عدم قطعیت ضرایب و تفسیر مدل را توضیح دهید.

الزامات ویژه‌ی مسیر الف: NHANES

الف۱. پاسخ کمی سلامت. یک پیامد کمی مناسب مانند فشارخون، شاخص بدنی یا یک اندازه‌گیری آزمایشگاهی را به‌عنوان پاسخ انتخاب کنید. اگر سؤال اصلی شما درباره‌ی پیامد دودویی است، تحلیل آن در فاز سوم انجام می‌شود و برای این فاز یک پاسخ کمی مرتبط انتخاب کنید.

الف۲. مدل ساده و مدل تعدیل‌شده. یک مدل ساده با متغیر توضیحی اصلی و سپس یک مدل چندگانه با چند متغیر مرتبط مانند سن و جنس بسازید. تغییر ضریب متغیر اصلی را تفسیر کنید، بدون آن‌که صرفاً از تغییر ضریب نتیجه‌ی علّی بگیرید.

الف۳. تشخیص مدل و تبدیل. باقیمانده‌ها را بررسی کنید و اگر متغیرهای آزمایشگاهی یا پاسخ چوله‌اند، یک تبدیل مناسب را با دلیل آماری بررسی کنید.

الف۴. وزن‌های پیمایش. در گزارش توضیح دهید که تحلیل رگرسیون آموزشی ساده چه تفاوتی با تحلیل کامل پیمایش پیچیده دارد. اگر تیم درس کد وزن‌دار ارائه کند، نتیجه‌ی اصلی و تحلیل وزن‌دار را به‌عنوان مقایسه گزارش کنید.

الزامات ویژه‌ی مسیر ب: TCGA-BRCA

ب۱. تعریف پاسخ کمی و خلاصه‌های کم‌بعد. برای هماهنگی با رگرسیون خطی کتاب، یک پاسخ کمی معنادار تعریف کنید و متغیرهای مولکولی را به یک مجموعه‌ی محدود و قابل تفسیر تبدیل کنید؛ برای مثال چند ژن ازپیش تعیین‌شده یا چند امتیاز مسیر زیستی. استفاده از هزاران متغیر خام در یک رگرسیون چندگانه مجاز نیست.

ب۲. مدل Clinical-only. یک مدل رگرسیون خطی با تعداد محدودی متغیر بالینی و جمعیت‌شناختی ازپیش توجیه‌شده برازش کنید. ضرایب، فاصله‌های اطمینان، R^2 و نمودارهای باقیمانده را گزارش کنید.

ب۳. مدل Molecular-only. یک مدل دوم با همان پاسخ و فقط ویژگی‌های مولکولی محدود یا امتیازهای مسیر زیستی بسازید. تعداد متغیرها باید با حجم نمونه متناسب باشد و انتخاب آن‌ها نباید بر اساس جست‌وجوی پسینی برای بهترین نتیجه انجام شود.

ب۴. مدل Integrated / Multimodal. یک مدل سوم بسازید که متغیرهای بالینی و مولکولی را هم‌زمان شامل شود. سه مدل Clinical-only، Molecular-only و Integrated را از نظر ضرایب، R^2، خطای باقیمانده و تشخیص‌های مدل مقایسه کنید.

ب۵. تفسیر تغییر ضرایب و چندهم‌خطی. بررسی کنید افزودن وجه مولکولی چگونه ضرایب متغیرهای بالینی و عدم قطعیت آن‌ها را تغییر می‌دهد. همچنین همبستگی میان متغیرهای مولکولی و مسئله‌ی چندهم‌خطی را بررسی کنید.

ب۶. رعایت ساختار بیمار. تمام مدل‌ها باید روی مجموعه‌ای با یک مشاهده‌ی تحلیلی مستقل به ازای هر بیمار ساخته شوند. اگر برای یک بیمار چند نمونه وجود دارد، روش انتخاب یا خلاصه‌سازی باید پیش از برازش مدل ثبت شده باشد.

الزامات ویژه‌ی مسیر ج: NACC

ج۱. انتخاب پاسخ کمی شناختی یا عملکردی. یک نمره‌ی کمی شناختی یا عملکردی از UDS را به‌عنوان پاسخ انتخاب کنید و دامنه، جهت نمره و محدودیت‌های مقیاس آن را توضیح دهید.

ج۲. مدل UDS-only. یک مدل پایه با تعداد محدودی متغیر بالینی، شناختی یا جمعیت‌شناختی از UDS برازش کنید. متغیرها باید قبل از دیدن نتیجه و بر اساس سؤال آماری انتخاب شوند.

ج۳. مدل MRI-only. با همان پاسخ، یک مدل دوم با تعداد محدودی متغیر MRI بسازید و ضرایب، R^2 و نمودارهای تشخیصی را گزارش کنید. اگر متغیرهای MRI به‌شدت همبسته‌اند، مسئله‌ی چندهم‌خطی را توضیح دهید.

ج۴. مدل UDS + MRI. یک مدل چندگانه بسازید که هر دو وجه را هم‌زمان شامل شود. مدل‌های UDS-only، MRI-only و UDS + MRI را از نظر ضرایب، برازش، خطای باقیمانده و عدم قطعیت مقایسه کنید. هدف فهم نقش آماری هر وجه است، نه ساخت بهترین سامانه‌ی پیش‌بینی.

ج۵. ساختار مراجعه‌های تکراری. مدل اصلی باید بر یک مشاهده‌ی مستقل به ازای هر شرکت‌کننده استوار باشد. قاعده‌ی انتخاب مراجعه و نزدیک‌بودن زمانی UDS و MRI باید مستند شود.

ج۶. تشخیص مدل و نقاط اثرگذار. برای مدل نهایی، باقیمانده‌ها، تغییر واریانس، نقاط دورافتاده و مشاهدات اثرگذار را بررسی کنید. حذف خودکار شرکت‌کننده مجاز نیست و اثر مشاهده‌های خاص باید مستند شود.

خروجی فاز چهارم: `reports/phase4.pdf`، کد کامل رگرسیون، نمودارهای تشخیصی، جدول ضرایب و برچسب `phase-4`.

۹. فاز پنجم ـ تحلیل تکمیلی، استحکام و جمع‌بندی

بازه: ۱۵ دی تا ۵ بهمن **امتیاز: ۲۵ از ۱۰۰**

در فاز پنجم باید تمام مراحل قبل را به یک تحلیل منسجم تبدیل کنید و بررسی کنید آیا نتیجه‌ی اصلی فقط محصول یک انتخاب خاص در آماده‌سازی داده یا مدل‌سازی بوده است یا در برابر انتخاب‌های معقول دیگر نیز باقی می‌ماند. هدف این فاز یک گزارش علمی کامل و قابل دفاع است، نه الزام به آماده‌سازی پروژه برای چاپ.

تسک‌های مشترک

۱. مرور کوتاه مطالعات مرتبط. حداقل سه منبع مرتبط با سؤال خود پیدا کنید و در یک جدول کوتاه، داده، سؤال، روش آماری اصلی و نتیجه‌ی کلیدی آن‌ها را خلاصه کنید. هدف، قراردادن تحلیل شما در زمینه‌ی علمی است؛ نیازی به ادعای نوآوری نیست.

۲. **تحلیل حساسیت نسبت به تعریف نمونه.** حداقل یک بار تحلیل اصلی را با یک معیار ورود و خروج معقول جایگزین تکرار کنید و بررسی کنید نتیجه تا چه حد تغییر می‌کند.

۳. **تحلیل حساسیت نسبت به تعریف متغیر.** اگر برای یک متغیر بیش از یک تعریف معقول وجود دارد، حداقل یک تعریف جایگزین را بررسی کنید. اگر چنین حالتی وجود ندارد، دلیل آن را بنویسید و تحلیل حساسیت دیگری انتخاب کنید.

۴. **تحلیل حساسیت نسبت به نقاط دورافتاده.** نتیجه‌ی رگرسیون یا برآورد اصلی را با و بدون چند مشاهده‌ی بسیار اثرگذار، فقط پس از شناسایی و گزارش شفاف آن‌ها، مقایسه کنید. حذف دائمی مشاهدات بدون دلیل علمی مجاز نیست.

۵. **مقایسه‌ی روش پارامتری و بازنمونه‌گیری.** برای یک کمیت مهم، فاصله‌ی اطمینان استاندارد را با فاصله‌ی bootstrap مقایسه و علت شباهت یا تفاوت آن‌ها را توضیح دهید.

۶. **تحلیل زیرگروه، در صورت معنادار بودن.** یک زیرگروه از پیش قابل توجیه را بررسی کنید و روشن کنید این تحلیل اکتشافی است یا از ابتدا در سؤال شما وجود داشته است. از ساخت تعداد زیادی زیرگروه صرفاً برای یافتن نتیجه‌ی معنی‌دار پرهیز کنید.

۷. **جمع‌بندی شواهد.** نتایج فازهای توصیفی، احتمالی، استنباطی و رگرسیونی را کنار هم قرار دهید و توضیح دهید کدام یافته‌ها با یکدیگر سازگارند و کجاها تفاوت یا عدم قطعیت وجود دارد.

۸. **محدودیت و دامنه‌ی ادعا.** محدودیت‌های نمونه‌گیری، مشاهده‌ای بودن داده، اندازه‌گیری، داده‌ی گمشده، تکرار مشاهدات و مدل آماری را بررسی کنید و دقیقاً مشخص کنید چه ادعاهایی از داده پشتیبانی می‌شوند و چه ادعاهایی نمی‌شوند.

الزامات ویژه‌ی مسیر الف: NHANES

الف۱. مقایسه‌ی وزن‌دار و بدون وزن. حداقل یک نتیجه‌ی اصلی را با و بدون وزن‌های نمونه‌گیری مقایسه کنید و درباره‌ی تغییر برآورد یا عدم قطعیت توضیح دهید.

الف۲. بازتولید در یک دوره‌ی دیگر، در صورت امکان. اگر متغیرهای اصلی در یک دوره‌ی قبلی **NHANES** با تعریف سازگار وجود دارند، یک نتیجه‌ی کلیدی را در آن دوره تکرار کنید. اگر سازگاری تعریف متغیرها کافی نیست، این محدودیت را مستند کنید و یک حساسیت جایگزین انجام دهید.

الف۳. بررسی ناهمگنی منطقی. یک تفاوت از پیش قابل توجیه میان دو زیرگروه، مانند بازه‌های سنی، را بررسی کنید و از تفسیر بیش از حد نتایج زیرگروهی پرهیز کنید.

الزامات ویژه‌ی مسیر ب: TCGA-BRCA

ب۱. حذف یک وجه داده و مقایسه‌ی چندوجهی. مقایسه‌ی Clinical-only، Molecular-only و Integrated را به‌صورت نهایی ارائه کنید و نشان دهید حذف وجه مولکولی یا بالینی چه تغییری در نتیجه‌ی اصلی ایجاد می‌کند.

ب۲. حساسیت نسبت به نبودن انواع داده. نتیجه‌ی اصلی را روی بیماران دارای داده‌ی کامل در همه‌ی وجوه با یک تعریف گسترده‌تر و قابل دفاع از نمونه مقایسه کنید و توضیح دهید حذف افراد فاقد یک وجه چگونه می‌تواند ترکیب نمونه را تغییر دهد.

ب۳. تحلیل زیرگروه یا زیرنوع مولکولی. حداقل یک تحلیل محدود و ازپیش توجیه‌شده در یک زیرگروه بالینی یا زیرنوع مولکولی انجام دهید. اندازه‌ی نمونه، عدم قطعیت و اکتشافی یا تأییدی بودن تحلیل را شفاف گزارش کنید.

ب۴. استحکام انتخاب ویژگی مولکولی. اگر نتیجه به چند ویژگی یا امتیاز مولکولی خاص وابسته است، یک تعریف جایگزین معقول یا مجموعه‌ی محدود دیگری که از قبل قابل دفاع است بررسی کنید و نشان دهید نتیجه‌ی اصلی تا چه حد به این انتخاب حساس است.

الزامات ویژه‌ی مسیر ج: NACC

ج۱. مقایسه‌ی نهایی سه مدل. مدل‌های UDS-only، MRI-only و UDS + MRI را در یک جدول نهایی مقایسه کنید و توضیح دهید اضافه‌شدن هر وجه چه تغییری در ضرایب، برازش و عدم قطعیت ایجاد می‌کند.

ج۲. حساسیت نسبت به کامل‌بودن UDS و MRI. تحلیل اصلی را در افراد دارای داده‌ی کامل در هر دو وجه با یک تحلیل جایگزین قابل دفاع مقایسه کنید و توضیح دهید محدودشدن به افراد دارای MRI کامل چه اثری ممکن است بر ترکیب نمونه داشته باشد.

ج۳. حساسیت نسبت به انتخاب مراجعه. اگر برای برخی شرکت‌کنندگان بیش از یک مراجعه وجود دارد، یک قاعده‌ی معقول جایگزین برای انتخاب مراجعه‌ی شاخص بررسی کنید و نشان دهید نتیجه‌ی اصلی تا چه حد تغییر می‌کند.

ج۴. تحلیل زیرگروه یا تحلیل زمانی محدود. در صورت وجود حجم نمونه‌ی کافی، یک مقایسه‌ی محدود بر اساس وضعیت شناختی، گروه سنی، جنس یا فاصله‌ی زمانی انجام دهید. روش باید با مباحث درس سازگار باشد و استقلال مشاهدات رعایت شود.

ج۵. جمع‌بندی ارزش تحلیل چندوجهی. در چند پاراگراف دقیق توضیح دهید استفاده‌ی هم‌زمان از UDS و MRI چه اطلاعاتی نسبت به هر وجه به‌تنهایی اضافه کرده و چه محدودیت‌هایی مانع تفسیر قوی‌تر می‌شوند.

خروجی فاز پنجم: گزارش نهایی، کد نهایی قابل بازتولید، جدول و شکل نهایی، فایل محدودیت‌ها و تحلیل حساسیت و برچسب `phase-5-final`.

۱۰. ساختار گزارش نهایی

گزارش نهایی باید یک گزارش علمی منسجم باشد و حداقل بخش‌های زیر را داشته باشد:

۱. **خلاصه:** سؤال، داده، روش‌های اصلی و مهم‌ترین نتیجه در یک صفحه یا کمتر؛

۲. **سؤال و طراحی مطالعه:** واحد مشاهده، نوع مطالعه، سازوکار انتخاب داده و دامنه‌ی تعمیم؛

۳. **داده و آمار توصیفی:** متغیرها، داده‌ی گمشده، جدول‌ها و شکل‌های اصلی؛

۴. **تحلیل احتمال:** رویدادها، احتمال‌های شرطی و توزیع‌های منتخب؛

۵. **استنباط آماری:** برآوردها، فاصله‌های اطمینان، آزمون‌ها و bootstrap؛

۶. **رگرسیون و همبستگی:** مدل ساده و چندگانه، تفسیر ضرایب و تشخیص مدل؛

۷. **تحلیل حساسیت و استحکام:** نتایج فاز پنجم؛

۸. **بحث و محدودیت‌ها:** آنچه می‌توان و نمی‌توان از داده نتیجه گرفت؛

۹. **جمع‌بندی:** پاسخ نهایی به سؤال اصلی؛

۱۰. **منابع و پیوست:** منابع، جزئیات تکمیلی و خروجی‌های فرعی.

تصویر صفحه از خروجی نرم‌افزار به‌جای جدول یا شکل استاندارد پذیرفته نیست. همه‌ی شکل‌ها باید عنوان، برچسب محور، واحد و توضیح قابل فهم داشته باشند.

۱۱. بازتولیدپذیری و GitHub

کار با GitHub بخشی از مهارت‌های مورد ارزیابی پروژه است و **مرجع اصلی تحویل، تاریخچه‌ی کار و بررسی روند انجام پروژه، مخزن GitHub خواهد بود.** همه‌ی خروجی‌های هر فاز باید تا ددلاین همان فاز در مخزن قرار بگیرند.

علاوه بر GitHub، در سامانه‌ی CW نیز یک بخش جداگانه برای تحویل پروژه باز خواهد شد. در این بخش باید یک فایل ZIP شامل **PDF گزارش، تمام کدهای پروژه، نوت‌بوک‌ها، شکل‌ها، فایل‌های راهنما و سایر خروجی‌های لازم** بارگذاری شود. تحویل در CW جایگزین GitHub نیست؛ هر دو بخش باید طبق دستورالعمل تیم درس تکمیل شوند. فایل‌های خام و حجیم مجموعه‌داده، مگر در صورت اعلام صریح تیم دستیاری، نباید داخل فایل ZIP یا مخزن قرار گیرند.

مهلت تحویل در هر فاز قطعی است و تحت هیچ شرایطی تمدید نخواهد شد.

ساختار پیشنهادی:

```
README.md
PROJECT_CARD.md

data/
    README.md

src/
notebooks/
figures/
```

```
reports/
    phase1/
    phase2/
    phase3/
    phase4/
    final/

environment.yml
# or
requirements.txt
```

خود فایل‌های بزرگ داده نباید در GitHub بارگذاری شوند. فایل `data/README.md` باید منبع رسمی داده، فایل‌های لازم، تاریخ دریافت و مراحل بازسازی مجموعه‌داده‌ی تحلیلی را توضیح دهد.

در پایان هر فاز برچسب متناظر `phase-1`، `phase-2`، `phase-3`، `phase-4` و `phase-5-final` ایجاد شود. قرار دادن کل پروژه در یک ثبت تغییر نهایی، روند کاری مناسب محسوب نمی‌شود.

۱۲. اصالت کار و سلامت آموزشی

پروژه کاملاً انفرادی است. شباهت غیرعادی و بدون توضیح موجه میان دو یا چند پروژه در سؤال، انتخاب متغیرها، ترتیب تحلیل، کد، متن، شکل‌ها، جدول‌ها یا نتایج بررسی خواهد شد. در صورت احراز همکاری غیرمجاز یا کپی، نمره‌ی پروژه برای افراد درگیر صفر در نظر گرفته می‌شود.

کد آغازین که مستقیماً توسط تیم دستیاری ارائه شود از این قاعده مستثناست. استفاده از کتابخانه‌های عمومی مجاز است، اما باید بتوانید هر بخش اساسی از کد و تحلیل خود را در جلسه‌ی دفاع توضیح دهید.

۱۳. اصول آماری مورد انتظار

- معنی‌دارنشدن نتیجه باعث کاهش نمره نمی‌شود؛ تحلیل صحیح یک نتیجه‌ی غیرمعنی‌دار می‌تواند نمره‌ی کامل بگیرد.
- فرضیه را پس از دیدن نتیجه طوری تغییر ندهید که نتیجه‌ی موجود معنی‌دار شود. اگر تحلیل اکتشافی است، صریحاً آن را اکتشافی بنامید.
- داده را بدون دلیل علمی یا قاعده‌ی از پیش توضیح‌داده‌شده حذف نکنید.
- مقدار p-value را بدون اندازه‌ی اثر و فاصله‌ی اطمینان گزارش نکنید.
- همبستگی و رگرسیون در داده‌ی مشاهده‌ای به‌تنهایی رابطه‌ی علّی را اثبات نمی‌کنند.
- فرض استقلال را جدی بگیرید؛ به‌خصوص در داده‌های چندفایلی و چندنمونه‌ای **TCGA-BRCA** و داده‌های چندمراجعه‌ای **NACC**.
- همه‌ی تصمیم‌های مهم آماده‌سازی داده باید در گزارش قابل ردیابی باشند.

۱۴. شیوه‌ی نمره‌دهی، ارائه و ضریب تسلط

ارزیابی پروژه در دو مرحله‌ی مستقل انجام می‌شود تا هم کیفیت فایل‌ها و تحلیل مکتوب سنجیده شود و هم مشخص شود دانشجو بر تمام بخش‌های پروژه‌ی خود تسلط دارد.

۱. **مرحله‌ی اول ـ ارائه‌ی آفلاین و نمره‌دهی مستقل فایل‌ها:** ابتدا ارائه‌ی آفلاین پروژه و تمام فایل‌های تحویلی شامل گزارش، کد، نوت‌بوک‌ها، شکل‌ها، جدول‌ها و سایر خروجی‌های تعیین‌شده، بدون درنظرگرفتن ضریب تسلط و براساس معیارهای اعلام‌شده ارزیابی می‌شوند. حاصل این مرحله **امتیاز خام پروژه** است. در مسیر الف این امتیاز حداکثر ۱۰۰ و در مسیرهای ب و ج، با احتساب ۱۰ امتیاز اضافه‌ی مسیر چندوجهی، حداکثر ۱۱۰ خواهد بود.

۲. **مرحله‌ی دوم ـ دفاع آنلاین یا حضوری و تعیین ضریب تسلط:** پس از ارزیابی آفلاین، تیم دستیاری یک جلسه‌ی ارائه و پرسش‌وپاسخ **آنلاین یا حضوری** برگزار می‌کند. در این جلسه، براساس میزان تسلط واقعی دانشجو بر سؤال پروژه، داده، کد، روش‌های آماری، تصمیم‌های تحلیلی، نتایج و محدودیت‌ها، یک **ضریب تسلط بین ۰ تا ۱** تعیین می‌شود. این ضریب بر امتیاز خام مرحله‌ی اول اعمال خواهد شد.

فرمول نمره‌ی نهایی پروژه:

نمره‌ی نهایی پروژه = امتیاز خام پروژه × ضریب تسلط

برای مثال، اگر مجموع ارزیابی فایل‌ها و ارائه‌ی آفلاین شما **۹۰ از ۱۰۰** باشد و در جلسه‌ی دفاع ضریب تسلط ۰٫۷ دریافت کنید، نمره‌ی نهایی پروژه برابر خواهد بود با:

۹۰ × ۰٫۷ = ۶۳

بنابراین نمره‌ی نهایی پروژه در این مثال **۶۳ از ۱۰۰** خواهد بود. برای مسیرهای ب و ج نیز همین ضریب روی کل امتیاز خام، شامل امتیاز اضافه‌ی مسیر، اعمال می‌شود.

در جلسه‌ی دفاع ممکن است درباره‌ی تعریف سؤال، واحد مشاهده، دلیل انتخاب نمودار یا آزمون، محاسبه‌ی احتمال، تفسیر فاصله‌ی اطمینان، معنی p-value، تفسیر ضریب رگرسیون، فرض‌های مدل، نمودار باقیمانده، داده‌ی گمشده، کد و محدودیت‌های پروژه سؤال شود. همچنین ممکن است از شما خواسته شود بخشی از کد، یک جدول، یک شکل یا یک تصمیم آماری را همان‌جا توضیح دهید.

تاریخ، مدت جلسه، آنلاین یا حضوری‌بودن آن، ترتیب ارائه‌ها و اعضای تیم ارزیابی‌کننده بعداً از طریق کانال رسمی درس اعلام خواهد شد.

۱۵. تغییر احتمالی بارم پروژه

اگر آزمون میان‌ترم یا پایان‌ترم به‌صورت مجازی برگزار شود، ممکن است سهم پروژه در نمره‌ی نهایی درس افزایش یابد. هر تغییر در بارم یا شیوه‌ی ارزیابی پیش از اعمال از مسیر رسمی درس اعلام خواهد شد.

۱۶. جمع‌بندی تیم دستیاری

از نظر ما یک پروژه‌ی قوی لزوماً پیچیده‌ترین پروژه نیست. پروژه‌ی قوی پروژه‌ای است که سؤال روشن داشته باشد، داده را درست بشناسد، روش متناسب با سؤال انتخاب کند، تفاوت توصیف و استنباط را رعایت کند، عدم قطعیت را گزارش کند، فرض‌های آماری را بررسی کند، رابطه را با علیت اشتباه نگیرد، و تمام مسیر تحلیل را به‌شکلی قابل بازتولید و قابل دفاع ارائه دهد.

در طول ترم ممکن است برای هر فاز قالب فایل، مثال اجرایی یا نکته‌ی تکمیلی منتشر شود. مسئولیت پیگیری آخرین نسخه‌ی دستورالعمل بر عهده‌ی دانشجو است.